ĐỀ XUẤT NGHIÊN CỨU

CogMem: Khung Kiến Trúc Bộ Nhớ Dựa Trên Khoa Học Nhận Thức Cho Tác Nhân Hội Thoại Dài Hạn

Chủ đề	Kiến trúc bộ nhớ và cơ chế truy xuất dựa trên khoa học nhận thức cho AI hội thoại dài hạn
Benchmark	LongMemEval-S, LoCoMo-10 — Đánh giá theo Recall@3, @5, @10
Baseline	HINDSIGHT (Latimer et al., 2025) — SOTA hiện tại trên cả 2 benchmark
Khoảng trống	Các hệ thống hiện tại thiếu nền tảng khoa học nhận thức trong cả kiến trúc lưu trữ lẫn cơ chế truy xuất

1. Động Lực Nghiên Cứu

Các hệ thống bộ nhớ dài hạn cho tác nhân AI đã có bước tiến đáng kể. Hệ thống HINDSIGHT tổ chức bộ nhớ thành các mạng có cấu trúc và sử dụng pipeline truy xuất đa chiến lược, đạt kết quả SOTA trên LongMemEval và LoCoMo. Tuy nhiên, khi xem xét kỹ, một quan sát quan trọng nổi lên: các hệ thống này được thiết kế hoàn toàn từ góc độ khoa học máy tính mà không có nền tảng từ cách bộ nhớ con người thực sự hoạt động.

Bộ nhớ con người không phải là một cơ sở dữ liệu phẳng. Đó là một hệ thống có cấu trúc phong phú với các hệ con riêng biệt phục vụ các vai trò nhận thức khác nhau — từ ký ức cá nhân (episodic), tri thức thế giới (semantic), đến các mẫu hành vi thủ tục (procedural) và ý định tương lai (prospective). Quan trọng hơn, quá trình truy xuất bộ nhớ của não người không phải là tìm kiếm vector tĩnh: đó là quá trình lan truyền kích hoạt động, tích lũy bằng chứng từ nhiều tín hiệu yếu và duyệt qua các con đường liên kết mà không cần điểm vào chính xác.

Đề xuất này xác định hai khoảng trống cụ thể trong các hệ thống hiện tại và đề xuất CogMem — một framework giải quyết cả hai thông qua ứng dụng có nguyên tắc của khoa học nhận thức.

2. Phân Tích Khoảng Trống Của SOTA Hiện Tại

2.1 Khoảng Trống Kiến Trúc Bộ Nhớ

HINDSIGHT tổ chức bộ nhớ thành 4 mạng: World, Experience, Opinion và Observation. Khi đối chiếu với phân loại bộ nhớ người, một sự không khớp quan trọng xuất hiện:

Mạng HINDSIGHT	Tương đương trong não người	Trạng thái
World Network	Semantic Memory (tri thức thế giới)	Ánh xa dung
Experience Network	Episodic Memory (ky uc ca nhan)	Anh xa dung
Opinion Network	Belief System (he thong niem tin)	Anh xa dung
Observation Network	Khong co tuong duong (chi la cache)	Can thay the
(thieu)	Procedural Memory (tri nho thu tuc)	Chua duoc bieu dien
(thieu)	Prospective Memory (tri nho tuong lai)	Chua duoc bieu dien
(thieu)	Working Memory (bo nho lam viec)	Chua duoc bieu dien

Mạng Observation, được định nghĩa là 'tóm tắt entity trung lập', không có tương đương thực sự trong phân loại bộ nhớ nhận thức. Quan trọng hơn, hai hệ thống bộ nhớ đã được nghiên cứu kỹ hoàn toàn vắng mặt: Procedural Memory (các mẫu hành vi và thói quen) và Prospective Memory (ý định và kế hoạch tương lai). Hai loại này lưu trữ thông tin về chất khác với episodic hay semantic memory và rất quan trọng cho hành vi tác nhân cá nhân hóa.

2.2 Khoảng Trống Cơ Chế Truy Xuất

HINDSIGHT sử dụng 4 kênh truy xuất song song (semantic, BM25, graph traversal, temporal) được gộp qua Reciprocal Rank Fusion. Tuy nhiên, kiến trúc này có hai hạn chế cơ bản:

- RRF trọng số bằng nhau cố định: Cả 4 kênh được trọng số bằng nhau bất kể loại query. Một câu hỏi về thời gian và một câu hỏi multi-hop nhận trọng số kênh giống hệt nhau, dẫn đến độ chính xác truy xuất không tối ưu.
- Lan truyền kích hoạt theo MAX: Graph traversal của HINDSIGHT dùng MAX — chỉ lấy con đường mạnh nhất đến mỗi node. Điều này loại bỏ tích lũy bằng chứng đa con đường — cơ chế cốt lõi của recall liên kết ở người. Khi nhiều tín hiệu yếu cùng chỉ đến một ký ức, não người khuếch đại độ nổi bật của ký ức đó. HINDSIGHT không thể tái tạo hành vi này.

Hệ quả rõ ràng trong kết quả benchmark: các category multi-hop và multi-session luôn đạt điểm thấp nhất — 64.58% multi-hop trên LoCoMo, 79.7% multi-session trên LongMemEval — chính xác là các category đòi hỏi duyệt qua nhiều liên kết liên kết.

3. Framework Đề Xuất: CogMem

CogMem giải quyết cả hai khoảng trống thông qua hai đóng góp bổ trợ nhau: kiến trúc bộ nhớ nhận thức phong phú hơn và cơ chế truy xuất động lấy cảm hứng từ Mô hình Bộ Nhớ Làm Việc của Baddeley.

3.1 Đóng Góp 1 — Kiến Trúc Bộ Nhớ Nhận Thức

3.1.1 Thiết Kế Lại Các Mạng

CogMem thay thế 4 mạng của HINDSIGHT bằng 5 mạng có nền tảng nhận thức:

Mạng	Cơ sở nhận thức	Lưu trữ gì	Ví dụ
World	Semantic Memory	Sự kiện khách quan	"DI chuyên về LLM infrastructure"
Experience	Episodic Memory	Sự kiện cá nhân trong quá khứ	"User vào làm DI tháng 4/2024"
Opinion	Belief System	Nhận xét chủ quan + độ tin cậy	"Python tốt nhất cho ML (0.85)"
Pattern [MỚI]	Procedural Memory	Mẫu hành vi và thói quen	"User hay check email trước standup"
Intention [MỚI]	Prospective Memory	Kế hoạch và mục tiêu tương lai	"User định học Rust trước Q3"
Action [MỚI]	Action-Effect Learning	Bộ ba nhân quả hành động-kết quả	"Lọc shop rating cao → giao hàng nhanh hơn"

3.1.2 Tại Sao Bỏ Observation Network

Mạng Observation bị loại bỏ vì hai lý do: (1) không có nền tảng trong phân loại khoa học nhận thức — thực chất chỉ hoạt động như một bộ nhớ đệm, không phải loại bộ nhớ thực sự; (2) chức năng tóm tắt entity của nó có thể được tích hợp tự nhiên vào World và Experience network thông qua narrative fact extraction có độ chi tiết theo entity.

3.1.3 Pattern Network — Procedural Memory

Pattern Network lưu trữ các quy luật hành vi ngầm được trích xuất từ các quan sát lặp lại xuyên phiên. Không giống episodic facts ghi lại sự kiện cụ thể, patterns nắm bắt các quy luật thống kê:

- "User thường hỏi gợi ý nhà hàng vào giờ trưa"
- "User thích độ sâu kỹ thuật hơn tóm tắt cấp cao khi hỏi về ML"
- "User thường bắt đầu ngày làm việc bằng cách kiểm tra tin tức công nghệ"

Các patterns này phục vụ hai mục đích: (1) làm phong phú context truy xuất cho các query nhạy cảm với sở thích, và (2) cung cấp prior cho cơ chế Episodic Buffer để hướng dẫn quá trình lan truyền kích hoạt.

3.1.4 Intention Network — Prospective Memory

Intention Network lưu trữ thông tin hướng tương lai kèm thời hạn hiệu lực:

- "User dự định chuyển nhà vào tháng 3/2025" — hiệu lực đến tháng 3/2025
- "User đang có kế hoạch apply vị trí senior tại VNG" — hiệu lực cho đến khi được giải quyết

Quan trọng, các Intention node có cơ chế hết hạn: khi thời điểm dự kiến qua đi hoặc một fact mâu thuẫn được lưu, node chuyển sang Experience network như một intention đã được thực hiện. Điều này phản ánh trải nghiệm của con người về việc ký ức tương lai hoặc được hoàn thành hoặc bị quên đi.

3.1.5 Action Network — Action-Effect Learning

Action Network có nền tảng từ Action-Effect Learning Theory (Hommel et al., 2001 — Theory of Event Coding), chứng minh rằng não người mã hóa tường minh các ánh xạ nhân quả giữa hành động chủ ý và hậu quả nhận thức của chúng. Điều này khác với Procedural Memory (Pattern Network) vốn nắm bắt tần suất thống kê của hành vi. Action-Effect knowledge là một mô hình nhân quả tường minh hỗ trợ reasoning hướng mục tiêu: não người truy xuất 'hành động nào gây ra trạng thái mong muốn Y' thay vì 'user thường làm gì'.

Action Network lưu trữ các bộ ba điều kiện-hành động-kết quả kèm điểm tin cậy:

Trường	Mô tả	Ví dụ
Precondition	Bối cảnh xảy ra hành động	"Đặt đồ ăn trong giờ trưa"
Action	Hành động chủ ý được thực hiện	"Lọc shop rating > 4.5"
Outcome	Hậu quả quan sát được	"Giao hàng nhanh hơn, ít khiếu nại hơn"
Confidence	Độ mạnh bằng chứng (0-1)	0.87 (quan sát 12 lần)
Edge type	Loại cạnh mới trong KG	causal_action edge

Action Network là cơ chế nhận thức chính để trả lời các Causal Inference queries — category khó nhất trong cả LongMemEval và AMA-Bench. Trên AMA-Bench, HippoRAG2 chỉ đạt 0.508, AMA-Agent đạt 0.614 trên Causal Inference. Action Network tấn công trực tiếp vào đây bằng cách cung cấp các chain precondition-action-outcome tường minh thay vì dựa vào graph traversal để suy luận nhân quả ngầm.

3.1.6 Phân Biệt với Pattern Network và Mem^p

Khái niệm	Loại	Độ chi tiết	Mục đích	Ví dụ
Pattern Network	Quy luật thống kê	Thói quen cấp phiên	Cá nhân hóa	"User hay order đồ ăn lúc 11h"
Mem^p (prior work)	Quy trình cấp task	Transfer xuyên task	Giảm bước khám phá	"Để hâm trứng: tủ lạnh → lò vi sóng"
Action Network (ours)	Nhân quả hành động-hiệu ứng	Bộ ba cấp action	Causal inference queries	"Lọc rating → kết quả tốt hơn"

Điểm khác biệt then chốt so với Mem^p (Fang et al., 2026) là độ chi tiết và mục đích: Mem^p lưu trữ script quy trình cấp task cho transfer xuyên task trong môi trường agentic, trong khi Action Network lưu trữ bộ ba nhân quả cấp action cho causal reasoning trong phiên trong môi trường bộ nhớ cá nhân.

3.2 Đóng Góp 2 — Siêu Dữ Liệu Node Không Mất Mát (Raw State Snippets)

3.2.1 Động Lực: Thất Bại Của Nén Mất Mát

Một phát hiện quan trọng từ AMA-Bench (Zhao et al., 2026) là nén mất mát (Lossy Compression) — cách tiếp cận chủ đạo trong các hệ thống bộ nhớ hiện tại — thất bại có hệ thống trên dữ liệu giàu thông tin. Case study của họ chứng minh trực tiếp: extractor của Mem0 trích xuất được 0 fact từ một đoạn trajectory 5.022 ký tự vì extractor được điều chỉnh cho ngôn ngữ tự nhiên, không phải state-observation log có cấu trúc. MemoryBank mất 41.3% độ chính xác sau construction vì cùng lý do.

Vấn đề tương tự xảy ra với bộ nhớ cá nhân: khi user chia sẻ code snippet, JSON config, bảng số liệu, hoặc URL — tóm tắt thành narrative facts sẽ mất các chi tiết chính xác mà retrieval thường cần trả về nhất.

3.2.2 Thiết Kế: Schema Node Hai Lớp

CogMem giải quyết điều này bằng cách tách mỗi KG node thành hai lớp:

Lớp	Nội dung	Dùng cho	Mất mát?
Narrative fact	Tóm tắt ngữ nghĩa do LLM trích xuất	Embedding, graph traversal, semantic search	Có — cố ý
Raw snippet	Văn bản nguồn gốc đính kèm metadata	Inject vào context window sau khi truy xuất	Không — lossless

Lớp narrative fact điều khiển toàn bộ quá trình retrieval — compact, embeddable, có thể duyệt đồ thị. Lớp raw snippet được đính kèm như metadata và chỉ xuất hiện khi node được chọn vào context window cuối cùng. Thiết kế này đảm bảo retrieval precision hưởng lợi từ nén ngữ nghĩa, trong khi chất lượng generation hưởng lợi từ độ trung thực nguồn không mất mát.

3.2.3 Schema Node

```
node = { id, network_type, narrative_fact, embedding, raw_snippet,
timestamp, confidence, expiry? }
```

Trường raw_snippet lưu đoạn nguồn nguyên văn — lượt hội thoại chính xác, code block, JSON object, hoặc giá trị số học từ đó narrative fact được trích xuất. Với LongMemEval và LoCoMo, điều này ngăn lỗi paraphrase trên các query Information Extraction như ngày tháng, tên riêng, và giá trị số. Với AMA-Bench, nó cho phép khôi phục không mất mát các machine-generated representations.

3.3 Đóng Góp 3 — Episodic Buffer với Spreading Activation

3.3.1 Nền Tảng Khoa Học Nhận Thức

Mô hình Bộ Nhớ Làm Việc của Baddeley (2000) giới thiệu Episodic Buffer như một không gian làm việc tích hợp tạm thời, liên kết thông tin từ các hệ con bộ nhớ dài hạn thành các episode mạch lạc. Quan trọng: đây không phải là lớp lưu trữ mà là quá trình truy xuất chủ động. CogMem vận hành hóa điều này thành cơ chế duyệt đồ thị động.

3.3.2 Cơ Chế: Tích Lũy Bằng Chứng Theo SUM

Đổi mới cốt lõi là thay thế lan truyền MAX của HINDSIGHT bằng tích lũy SUM:

Khía cạnh	HINDSIGHT (MAX)	CogMem Episodic Buffer (SUM)
Quy tắc lan truyền	A(v) = max của hàng xóm	A(v) = A(v) + delta * tổng hàng xóm
Bằng chứng đa con đường	Bị loại bỏ (chỉ lấy con đường tốt nhất)	Được tích lũy (mọi con đường đều đóng góp)
Yêu cầu điểm vào	Phải chính xác	Chỉ cần xấp xỉ là đủ
Độ bền vững multi-hop	Yếu — một liên kết sai phá vỡ cả chain	Mạnh — tín hiệu yếu bổ sung cho nhau
Kết thúc	Số bước cố định	Dựa trên ngưỡng hội tụ

Công thức lan truyền tại mỗi bước t (có cycle guards):

```
A(v, t+1) = clip[ A(v,t) + delta * SUM_{u in N(v)} [ A(u,t) * w(u,v)
* mu(loai_canh) * refractory(u) ] , A_max ]
```

Trong đó delta là hệ số suy giảm, w(u,v) là trọng số cạnh, mu(loai_canh) là hệ số nhân theo loại cạnh, refractory(u) = 0 nếu node u vừa phát sóng ở bước trước và = 1 nếu ngược lại, A_max là trần bão hòa. Buffer kết thúc khi delta activation tối đa giảm dưới ngưỡng epsilon hoặc hạn mức phát sóng toàn cục cạn kiệt.

3.3.3 Ba Cơ Chế Cycle-Guard

Lan truyền SUM thuần túy trên đồ thị có chu trình được đảm bảo về mặt toán học sẽ phân kỳ nếu không có cơ chế ngắt. CogMem triển khai ba cơ chế bổ sung cho nhau có nền tảng từ cả cognitive science và systems engineering:

Cơ chế	Nền tảng nhận thức	Vai trò kỹ thuật	Tham số
Thời kỳ trơ cục bộ (Local Refractory Period)	Thời kỳ trơ thần kinh — neuron không thể kích hoạt lại ngay sau khi phát sóng (Hodgkin & Huxley, 1952)	Chặn ping-pong: ngăn năng lượng dội ngược ngay lập tức giữa hai node kề nhau	refractory_steps = 1
Hạn mức phát sóng toàn cục (Global Firing Quota)	Giới hạn năng lực chú ý — bộ nhớ làm việc có chu kỳ kích hoạt giới hạn (Baddeley, 2000)	Chặn chu trình dài: mỗi node có số lần phát sóng tối đa mỗi query, ngăn kẹt vô hạn trong vòng lặp	max_fires = 3

Cơ chế	Nền tảng nhận thức	Vai trò kỹ thuật	Tham số
Ngưỡng bão hòa (Saturation Threshold)	Bão hòa thần kinh — kích hoạt không thể vượt trần sinh học (Wilson-Cowan model, 1972)	Chặn bùng nổ điểm số: kẹp (clip) điểm tích lũy tại A_max để ngăn phân kỳ SUM	A_max = 2.0

Ba cơ chế này không phải là tùy chọn nâng cao — chúng là yêu cầu tính đúng đắn. Không có Refractory Period, hai node kết nối mạnh sẽ dao động vô hạn. Không có Global Firing Quota, chu trình độ dài k sẽ giữ kích hoạt vô số bước. Không có Saturation Threshold, tích lũy SUM trên đồ thị dày đặc sẽ tràn mọi ngưỡng hội tụ hữu hạn. Cùng nhau, chúng đảm bảo kết thúc và đầu ra giới hạn trong khi bảo toàn tính chất tích lũy bằng chứng.

3.3.4 Ví Dụ Minh Họa

Query: "Dự án mà đồng nghiệp của tôi đang làm có liên quan đến thứ tôi quan tâm không?"

- Bước 0 — Khởi tạo: Semantic search kích hoạt F_dongNghiep (0.5), F_duAn (0.6), F_quanTam (0.7)
- Bước 1 — Lan truyền: F_duAn nhận kích hoạt từ F_dongNghiep qua entity edge VÀ từ F_quanTam qua semantic edge — cả hai cộng dồn
- F_duAn điểm cuối: 0.6 + (0.5*1.0*0.5) + (0.7*0.8*0.5) = 0.6 + 0.25 + 0.28 = 1.13
- F_duAn nổi lên đầu bảng xếp hạng dù không có keyword match trực tiếp — được truy xuất đúng nhờ bằng chứng đa con đường

Với MAX của HINDSIGHT: F_duAn chỉ đạt 0.6 + max(0.25, 0.28) = 0.88, bỏ lỡ bằng chứng cộng dồn từ cả hai con đường.

3.4 Đóng Góp 4 — Adaptive Query Routing

CogMem giới thiệu một bộ phân loại query nhẹ để điều chỉnh trọng số kênh RRF theo loại query được phát hiện:

Loại Query	Tín hiệu phát hiện	Trọng số kênh (sem / bm25 / graph / temp)
Temporal	Biểu thức ngày giờ, thời gian tương đối	0.2 / 0.2 / 0.2 / 0.4
Entity-centric	Tên riêng, danh từ riêng	0.2 / 0.3 / 0.4 / 0.1
Multi-hop	Đại từ quan hệ, tham chiếu gián tiếp	0.15 / 0.1 / 0.5 / 0.25
Semantic	Mô tả chung, không có entity/thời gian	0.5 / 0.2 / 0.2 / 0.1
Mặc định	Không rõ ràng	0.25 / 0.25 / 0.25 / 0.25

Bộ phân loại có thể được cài đặt dựa trên quy tắc (regex + nhận dạng thực thể đặt tên) để không tăng thêm latency, hoặc là một classifier nhỏ fine-tuned để đạt độ chính xác cao hơn. Đây trực tiếp giải quyết hạn chế RRF trọng số bằng nhau cố định của HINDSIGHT.

3.5 Đóng Góp 5 (Khám Phá) — Hierarchical Knowledge Graph

3.4.1 Nền Tảng Nhận Thức: Schema Theory

Schema Theory (Bartlett, 1932) và Basic Level Categorization (Rosch, 1978) chứng minh rằng bộ nhớ con người không được tổ chức như một danh sách facts phẳng, mà theo cấu trúc phân cấp — các schema trừu tượng bao gồm các thực thể cụ thể. Não người điều hướng hệ thống phân cấp này một cách tự nhiên: các query chung chung tiếp cận ở cấp độ trung gian, trong khi các query cụ thể sẽ drill down xuống cấp độ chi tiết. Các hệ thống bộ nhớ dựa trên KG hiện tại — bao gồm HINDSIGHT — lưu trữ tất cả facts ở cùng một cấp, buộc quá trình truy xuất phải quét toàn bộ không có định hướng.

3.4.2 Cấu Trúc Phân Cấp Đề Xuất

CogMem tùy chọn tổ chức facts thành ba cấp độ trừu tượng:

Cấp độ	Tên	Mô tả	Ví dụ
Level 0	Abstract	Schema cấp cao về người dùng	"User làm trong ngành AI/tech tại Hà Nội"
Level 1	Basic (anchor)	Facts cấp trung — đích truy xuất chính	"User là ML Engineer tại DI từ tháng 4/2024"
Level 2	Specific	Facts thực thể cấp thấp	"User vào DI tháng 4/2024", "User làm dự án RAG"

Level 1 đóng vai trò là lớp neo (anchor layer) — hầu hết các query tiếp cận ở đây trước. Episodic Buffer sau đó điều hướng xuống Level 2 để lấy chi tiết hoặc lên Level 0 cho reasoning trừu tượng. Điều này cung cấp các điểm vào chất lượng tốt hơn cho buffer và giảm nhiễu từ việc quét tất cả facts ở cùng độ phân giải.

3.4.3 Mối Quan Hệ với Episodic Buffer

Hierarchical KG và Episodic Buffer bổ trợ nhau một cách tự nhiên. Hệ thống phân cấp cung cấp các điểm vào có cấu trúc giúp cải thiện các hạt giống kích hoạt ban đầu cho spreading activation. Thay vì bắt đầu từ kết quả semantic search phẳng, buffer có thể neo tại các Level 1 node và lan truyền theo hướng có định hướng — xuống để lấy chi tiết, ngang để lấy entity liên quan, lên để lấy context trừu tượng. Sức mạnh kết hợp này là lý do chính để xem xét đóng góp này.

3.4.4 Chiến Lược Triển Khai

Việc xây dựng hierarchy được thực hiện trong giai đoạn retain bằng phương pháp dựa trên quy tắc nhẹ để tránh chi phí LLM bổ sung:

- Level 2 (Specific): Narrative facts trực tiếp được trích xuất từ hội thoại — giữ nguyên từ pipeline của HINDSIGHT
- Level 1 (Basic): Được tạo bằng cách nhóm các Level 2 facts có cùng entity chính và tóm tắt bằng một LLM call ngắn
- Level 0 (Abstract): Được tạo một lần cho mỗi entity bằng cách trừu tượng hóa từ các Level 1 node — cập nhật tăng dần khi Level 1 thay đổi

Các cạnh parent-child được thêm vào như một loại cạnh mới (hierarchical) cùng với các cạnh temporal, semantic, entity và causal hiện có. Điều này giữ cho sự thay đổi mang tính bổ sung và tương thích ngược.

3.4.5 Đánh Giá Phạm Vi và Rủi Ro

Tiêu chí	Đánh giá
Nền tảng nhận thức	Vững chắc — Schema Theory được thiết lập tốt trong cognitive science
Sức mạnh kết hợp với Episodic Buffer	Cao — cải thiện chất lượng điểm vào cho spreading activation
Tác động Recall@k dự kiến	Trung bình — một phần chồng lấp với lợi ích của Episodic Buffer
Độ phức tạp triển khai	Trung bình-cao — cần xây dựng hierarchy trong giai đoạn retain
Ưu tiên được khuyến nghị	Phase 5 — triển khai sau khi các đóng góp chính được xác nhận

4. Tổng Quan Kiến Trúc Hệ Thống

CogMem hoàn toàn tương thích ngược với pipeline retain của HINDSIGHT. Giai đoạn retain được mở rộng (không thay thế) để hỗ trợ các node Pattern, Intention, Action và tùy chọn Hierarchical. Tất cả đóng góp truy xuất nằm ở lớp recall:

Thành phần	Lớp	Thay thế / Mở rộng
Bộ nhớ 6 Mạng	Storage	Mở rộng 4 mạng của HINDSIGHT
Pattern Extractor	Retain	Mới: phát hiện các mẫu hành vi
Intention Extractor	Retain	Mới: phát hiện các phát biểu hướng tương lai
Action Extractor	Retain	Mới: trích xuất bộ ba nhân quả hành động-kết quả
Adaptive Query Router	Recall	Thay thế: RRF trọng số bằng nhau cố định
Episodic Buffer	Recall	Thay thế: lan truyền kích hoạt theo MAX
Convergence Controller	Recall	Mới: kết thúc dựa trên ngưỡng hội tụ
Hierarchical KG Builder	Retain (tùy chọn)	Mới: hệ thống phân cấp schema 3 cấp
Hierarchy-aware Navigator	Recall (tùy chọn)	Mới: chọn điểm vào có định hướng cấp độ

5. Thiết Kế Thực Nghiệm

5.1 Benchmark và Metric

- LongMemEval-S: 500 câu hỏi trên 6 category — Information Extraction, Multi-session Reasoning, Temporal Reasoning, Knowledge Update, Single-session, Abstention
- LoCoMo-10: 50 hội thoại, đánh giá trên Single-hop, Multi-hop, Open Domain và Temporal
- Metric chính: Recall@3, Recall@5, Recall@10

5.2 Các Baseline So Sánh

Hệ thống	Vai trò
HINDSIGHT (Paper)	SOTA đã công bố — mốc tham chiếu
HINDSIGHT (Rebuilt)	Bản tái tạo trên KG cố định — baseline chính để so sánh
MemOrai, HippoRAG2	Retrieval-only SOTA — so sánh trực tiếp Recall@k
Mem0, Zep, LangMem	Các hệ thống bộ nhớ tiền nhiệm
CogMem (Đầy đủ)	Framework chúng tôi đề xuất

5.3 Nghiên Cứu Ablation

Mỗi thành phần được đánh giá độc lập để cô lập đóng góp:

TN	Thành phần hoạt động	Kiểm tra gì
E1	HINDSIGHT Rebuilt	Độ trung thực tái tạo
E2	E1 + Pattern Network	Giá trị của Procedural Memory
E3	E1 + Intention Network	Giá trị của Prospective Memory
E4	E1 + Action Network	Giá trị của Action-Effect Learning
E5	E1 + Adaptive Query Router	Giá trị trọng số kênh
E6	E1 + Episodic Buffer (SUM)	Giá trị spreading activation
E7 (CogMem đầy đủ)	E1–E6 tất cả thành phần	Đóng góp kết hợp
E8 (Tùy chọn)	E7 + Hierarchical KG	Khám phá: lợi ích schema hierarchy
E9 (Tùy chọn)	E7 + World Knowledge Grounding	Khám phá: tri thức bên ngoài

5.4 Cách Báo Cáo Kết Quả

Kết quả được báo cáo theo 3 cột trên mỗi benchmark: HINDSIGHT (Paper) | HINDSIGHT (Rebuilt) | CogMem. Cải thiện được đo tương đối so với baseline Rebuilt để đảm bảo so sánh

công bằng trên cùng đồ thị tri thức cố định. Cách trình bày này thừa nhận rõ ràng sự chênh lệch tái tạo và được cộng đồng nghiên cứu chấp nhận rộng rãi.

6. Đóng Góp Dự Kiến & Tính Mới

6.1 Đóng Góp Chính

- Ánh xạ có hệ thống đầu tiên giữa kiến trúc bộ nhớ AI và phân loại bộ nhớ người, xác định và lấp đầy khoảng trống trong biểu diễn Procedural, Prospective và Action-Effect Memory — dẫn đến kiến trúc 6 mạng
- Action Network có nền tảng Action-Effect Learning Theory (Hommel et al., 2001) — bộ ba nhân quả hành động-kết quả tường minh tấn công trực tiếp Causal Inference queries, category khó nhất trong cả LongMemEval và AMA-Bench
- Episodic Buffer như cơ chế truy xuất chủ động với SUM-based spreading activation và cycle-guard mechanisms — khác biệt với các công trình trước đây xem working memory như lớp lưu trữ
- Adaptive Query Routing cho hệ thống truy xuất đa chiến lược — điều chỉnh động trọng số kênh theo loại query
- Hierarchical KG có nền tảng Schema Theory — trừu tượng hóa 3 cấp cho phép điều hướng truy xuất nhận thức độ phân giải (đóng góp khám phá)
- Đánh giá thực nghiệm trên LongMemEval và LoCoMo chứng minh cải thiện trên các category multi-hop, temporal và causal reasoning với phương pháp ablation sạch sẽ

6.2 Tính Mới So Với Công Trình Trước

Trong khi một số hệ thống gần đây (MMAG, MIRIX, MemoryOS, Mem^p) lấy cảm hứng từ cognitive science, chưa có công trình nào: (1) vận hành hóa Action-Effect Learning như mạng bộ nhớ nhân quả tường minh tách biệt với thói quen procedural, (2) vận hành hóa working memory như cơ chế spreading activation động với tích lũy bằng chứng theo SUM, (3) phân biệt và lưu trữ riêng biệt procedural vs. prospective vs. action-effect vs. episodic memory trong hệ thống dựa trên KG, hoặc (4) đánh giá trực tiếp các lựa chọn thiết kế này theo Recall@k. Đặc biệt, Action Network khác căn bản so với Mem^p (Fang et al., 2026): Mem^p lưu script quy trình cấp task cho transfer xuyên task trong môi trường agentic, trong khi Action Network lưu bộ ba nhân quả cấp action cho causal reasoning trong phiên trong môi trường bộ nhớ cá nhân.

6.3 Định Hướng Framing Bài Báo

> *"CogMem: Towards Cognitively-Grounded Memory for Long-Term Conversational Agents"*

HINDSIGHT được trích dẫn như một baseline công trình trước mạnh — không phải là hệ thống gốc mà CogMem cải thiện. Framing định vị CogMem là một framework mới có nền tảng cognitive science, giúp tránh bị đánh giá là incremental work và mở ra hướng nghiên cứu rộng hơn về bộ nhớ tác nhân AI.

7. Lộ Trình Thực Hiện

Giai đoạn	Công việc	Ưu tiên
Phase 1 — Baseline	Tái tạo pipeline recall của HINDSIGHT. Xây dựng và cố định KG từ LongMemEval + LoCoMo. Thiết lập số Rebuilt baseline.	Bắt buộc
Phase 2 — Core Retrieval	Cài đặt Episodic Buffer với SUM spreading activation + cycle guards (Refractory Period, Global Firing Quota, Saturation Threshold). Cài đặt Adaptive Query Router. Đo Recall@k trên cả 2 benchmark.	Bắt buộc
Phase 3 — Mạng bộ nhớ	Cài đặt Pattern Network extractor. Cài đặt Intention Network với cơ chế hết hạn. Cài đặt Action Network với causal triple extraction. Chạy ablation E2, E3, E4.	Cao
Phase 4 — Tích hợp	Tích hợp đầy đủ CogMem (E1-E7). Hoàn thành bảng ablation chính. Viết bài báo.	Cao
Phase 5 — Hierarchical KG	Xây dựng schema hierarchy 3 cấp. Thêm hierarchy-aware navigation vào Episodic Buffer. Chạy ablation E8.	Nếu còn thời gian
Phase 6 — Tùy chọn	Thí nghiệm World Knowledge Grounding (E9). Phân tích latency và hiệu suất.	Nếu còn thời gian

8. Tóm Tắt

CogMem đề xuất cách tiếp cận có nền tảng nhận thức cho bộ nhớ hội thoại dài hạn bằng cách giải quyết hai khoảng trống cấu trúc trong các hệ thống hiện tại: phân loại bộ nhớ chưa đầy đủ và cơ chế truy xuất không tích lũy bằng chứng. Bằng cách neo kiến trúc bộ nhớ vào cognitive science đã được thiết lập — Procedural Memory (Pattern Network), Prospective Memory (Intention Network), Action-Effect Learning (Action Network), và Schema Theory (Hierarchical KG) — và cơ chế truy xuất vào Baddeley's Working Memory Model (Episodic Buffer với SUM-based spreading activation và cycle-guard mechanisms), CogMem nhắm vào chính xác các category mà SOTA hiện tại yếu nhất. Action Network đặc biệt tấn công trực tiếp Causal Inference queries — category khó nhất trong cả LongMemEval và AMA-Bench — thông qua các bộ ba nhân quả action-outcome tường minh có nền tảng Action-Effect Learning Theory. Adaptive Query Routing bổ sung thêm bằng cách điều chỉnh động trọng số kênh theo loại query. Cùng nhau, các đóng góp này tạo thành một framework có nguyên tắc, có thể xác minh qua ablation với động cơ lý thuyết rõ ràng và khả năng đo lường thực nghiệm trực tiếp theo Recall@k trên LongMemEval và LoCoMo.